UNIVERSITÀ DEGLI STUDI DI BERGAMO MOBILE AND CLOUD TECHNOLOGIES

EMANUELE PERICO 1046601

CHRISTIAN CELESTINO 1046204

DESCRIZIONE JOB PYSPARK REALIZZATO

Il job scritto è composto da tre parti principali:

- Lettura del dataset watch_next_dataset.csv;
- Creazione del modello aggregato watch_next_dataset_agg;
- 3. Join di watch_next_dataset_agg a tedx_dataset_agg (contenente i dati del singolo TEDx talk con i relativi tag)

```
### READ WATCH_NEXT DATASET

watch_next_dataset_path = "s3://unibg-tedx-data-emanuele/watch_next_dataset.csv"

watch_next_dataset = spark.read.option("header","true").csv(watch_next_dataset_path)

### CREATE THE AGGREGATE MODEL, ADD WATCH_NEXT TO TEDX_DATASET

watch_next_dataset_agg = watch_next_dataset.groupBy(col("idx")).agg(collect_list("url").alias("wn_url"), collect_list("watch_next_idx").alias("wn_idx"))

watch_next_dataset_agg.printSchema()

# join fra il dataset iniziale (contenente anche i tags) e quello dei watch_next

tedx_dataset_watch_next_agg = tedx_dataset_agg.join(watch_next_dataset_agg, tedx_dataset_agg.id == watch_next_dataset_agg.idx, "left").drop("idx")

tedx_dataset_watch_next_agg.printSchema()
```

DATITRATTATI

tedx_dataset_agg

idx	main_speaker	title	details	posted	url	tag
Α	Pippo			apr-20	https://	#ted
В	Pluto	***	***	mag-20	https://	#science
С	Paperino		1	mar-20	https://	#tech



SELECT *
FROM tedx_dataset_agg
LEFT JOIN watch_next_dataset_agg
ON tedx_dataset_agg.idx=watch_next_dataset_agg.idx

watch_next_dataset_agg


idx	wn_url	wn_idx		
Α	https://	D		
Α	https://	E		
В	https://	F		
В	https://	G		
C	https://	н		

tedx_dataset_watch_next_agg

idx	main_speaker	title	details	posted	url	tag	wn_url	wn_idx
Α	Pippo	***	***	apr-20	https://	#ted	https://; https://	D; E
В	Pluto	***	***	mag-20	https://	#science	https://; https://	F; G
С	Paperino	***	***	mar-20	https://	#tech	https://	Н

SCHEMA FINALE

Schema ER



Mongo DB Visual

```
_id: "8c1fad5ce0dab8908dee527f88697ce2"

main_speaker: "Todd Dufresne"

title: "History vs. Sigmund Freud"

details: "Working in Vienna at the turn of the 20th century, he began his career..."

posted: "Posted Mar 2020"

url: "https://www.ted.com/talks/todd_dufresne_history_vs_sigmund_freud"

> tags: Array

> wn_url: Array

> wn_idx: Array
```

Query result di MongoDB

EVOLUZIONI

Per comodità e semplicità sarebbe preferibile raggruppare gli URL e gli ID dei watch_next sotto un'unica matrice, in modo da avere un unico oggetto contenente entrambi i campi di interesse.

Come fare?

Utilizzare la funzione struct di pyspark:

Ottenendo:

idx	main_speaker	title	details	posted	url	tag	watch_next	
Α	Pippo			apr-20	https://	#ted	wn_url	wn_idx
В	Pluto	***	***	mag-20	https://	#science	wn_url	wn_idx
С	Paperino	***	***	mar-20	https://	#tech	wn_url	wn_idx

```
id: "8c1fad5ce0dab8908dee527f88697ce2"
 main speaker: "Todd Dufresne"
 title: "History vs. Sigmund Freud"
 details: "Working in Vienna at the turn of the 20th century, he began his career..."
 posted: "Posted Mar 2020"
 url: "https://www.ted.com/talks/todd dufresne history vs sigmund freud"
> tags: Array
v watch next: Array
  v 0: Object
       wn id: "43014f52663d1cf317a606b9c4dfe2fd"
       url: "https://www.ted.com/talks/alex gendler history vs christopher columbus"
  v 1: Object
       wn id: "43014f52663d1cf317a606b9c4dfe2fd"
       url: "https://www.ted.com/talks/alex gendler history vs christopher columbus"
  > 2: Object
  > 3: Object
```

Visual MongoDB:

CRITICITÀ

Eventuali criticità riscontrate potrebbero essere ad esempio:

- Errori nei Dataset CSV, come errori di scrittura e di separazione dei campi
- Possibili duplicati che vanno ad appesantire il DataLake, risolvibili attraverso l'uso della funzione collect_set al posto della classica collect_list;
 - Nel nostro caso l'uso di questa funzione riduce lo spazio del nostro DataLake di circa la metà (da 12 MB a 7 MB)